

Sistema União de Monitoramento & Previsão Climática

Evolução da Ingestão de Dados (AV1) para Arquitetura de Microsserviços Desacoplada e Inteligência Preditiva (AV2)

Almir Sérgio Ramos dos Santos Filho

Curso de Ciência de Dados

19 de junho de 2026

1. Introdução e Objetivos da Transição (AV1 → AV2)

O Propósito da AV2


O projeto evoluiu de um painel puramente descritivo e estático para um **sistema modular de suporte à decisão com capacidade preditiva real**. A plataforma lida com o histórico meteorológico de 7 cidades brasileiras ao longo de 10 anos (2014–2023).

Diretrizes Estruturais Implementadas:

- **Desacoplamento Obrigatório:** Eliminação completa de conexões ou queries SQL diretas no front-end.
- **Inteligência Preditiva Integrada:** Inclusão de um módulo de aprendizado de máquina acoplável e controlado em tempo real pelo usuário.
- **Orquestração de Infraestrutura:** Isolamento absoluto de papéis (Banco, Back-end e Front-end) via contêineres independentes.

2. Nova Arquitetura do Ecossistema

Seguindo estritamente a especificação mínima de barreira de acesso, o fluxo de comunicação foi completamente isolado:



- **Isolamento de Segurança:** O Dashboard (`app.py`) consome dados exclusivamente por chamadas HTTP, sem credenciais diretas do banco.
- **Orquestração Dedicada:** Três serviços isolados e comunicantes mapeados no `docker-compose.yml`.

3. API Intermediária: Endpoints e Governança (api/main.py)

A camada de Back-end expõe endpoints parametrizados estruturados para otimização do tráfego de rede:

Método	Rota	Objetivo e Filtros Aplicados
GET	/health	Validação de saúde física e conectividade do ecossistema.
GET	/cidades	Fornecimento dinâmico das estações mapeadas para os seletores da UI.
GET	/resumo	Agregação direta no banco (médias térmicas e totais de chuva).
GET	/dados/{id}	Filtros por Query Params (ano_inicio e ano_fim) aplicados em SQL.

- **Otimização de Memória:** Os agrupamentos e filtros temporais são executados nativamente na base PostgreSQL, mitigando a sobrecarga de memória no front-end.
- **Documentação OpenAPI:** Interface interativa e testes de contrato disponíveis de forma automatizada na URL padrão `http://localhost:8000/docs`.

4. Ingestão e Reprodutibilidade Estatística (generator.py)

Para alimentar as previsões, o script gerador simula um cenário climático caótico, porém matematicamente estruturado com **semente fixa** (seed=42):

- **Sazonalidade Contínua:** Modelada por ondas senoidais e cossensidais com picos térmicos em janeiro e vales estruturais em julho.
- **Tendência de Longo Prazo (Aquecimento Global):** Injeção de uma inclinação linear de aquecimento de $+0.5^{\circ}\text{C}$ distribuída de forma homogênea ao longo dos 10 anos Simulados.
- **Ruído Complexo Combinado:** Convolução de ruído autorregressivo de longo período (simulando frentes frias duradouras) somada a uma distribuição normal diária de instabilidade pontual.
- **Pluviometria Acoplada:** Chuva gerada via amostragem de distribuição exponencial condicionada à estação do ano e à umidade relativa do ar.

5. Módulo Preditivo: Engenharia de Atributos (modelo.py)

O Desafio da Temporalidade

Inserir o dia bruto do ano (1 a 365) em modelos de aprendizado de máquina lineares ou baseados em árvores gera descontinuidade severa (o dia 365 e o dia 1 são vizinhos climáticos diretos, mas distantes numericamente).

Transformações Aplicadas no Pré-processamento:

- 1 Conversão da coluna `data_medicao` para tipo temporal estruturado e extração do ano civil.
- 2 Mapeamento cíclico do dia do ano através de transformações de coordenadas polares (Seno e Cosseno):

$$\sin_dia_ano = \sin\left(\frac{2 \cdot \pi \cdot dia_ano}{365.25}\right) \quad \text{e} \quad \cos_dia_ano = \cos\left(\frac{2 \cdot \pi \cdot dia_ano}{365.25}\right)$$

Dessa forma, a inteligência preditiva consegue mapear perfeitamente a continuidade das estações sem introduzir vieses de fronteira. Atributos de treinamento finais: `['ano', 'sin_dia_ano', 'cos_dia_ano']`.

6. Validação Temporal Estrita via Ponto de Corte (t_0)

Para séries temporais, validações cruzadas tradicionais aleatórias (*K-Fold*) quebram a dependência cronológica e vazam dados do futuro para o passado.

- **Configuração Interativa do Usuário (t_0):** Definido dinamicamente através de um seletor (*slider*) na interface do Streamlit.
- **Corte Temporal Rígido:**
 - **Conjunto de Treinamento:** Dados $< t_0$ (utilizado para ajustar os parâmetros internos do estimador).
 - **Conjunto de Teste/Avaliação:** Dados $\geq t_0$ (isolado completamente, simulando o futuro real para aferição de aderência).
- **Visualização Dinâmica:** Apresentação em gráfico de linha contínua para o histórico real e linha tracejada para a resposta predita sobreposta.

7. Justificativa Técnica dos Modelos Selecionados

O sistema disponibiliza de forma intercambiável dois modelos de naturezas matemáticas distintas no painel:

Regressão Linear (Scikit-Learn)

Motivação e Ajuste:

Excelente para capturar tendências de longo prazo explícitas. Ao receber os atributos cíclicos combinados ($\sin/\cos$), a Regressão Linear funciona como uma análise harmônica de Fourier, ajustando perfeitamente a variação sazonal da temperatura média ao longo das décadas com custo computacional nulo.

Random Forest Regressor

Motivação e Ajuste:

Modelo baseado em conjunto de árvores de decisão (*Ensemble*). É capaz de rastrear padrões não-lineares mais complexos e interações abruptas entre os ruídos de médio período inseridos. Os hiperparâmetros foram inspecionados para equilibrar variância e viés (limitação de profundidade para evitar *overfitting* na tendência linear).

8. Métricas de Avaliação e Interpretação de Negócio

Duas métricas de erro robustas são calculadas dinamicamente no conjunto de testes e exibidas na interface:

- **Erro Médio Absoluto (MAE):**

$$\text{MAE} = \frac{1}{n} \sum_{i=1}^n |y_i - \hat{y}_i|$$

Interpretação Prática: Mede a magnitude média do erro das previsões sem considerar sua direção. Um MAE de 1.2°C indica que as projeções térmicas da plataforma erram, em média, cerca de 1.2 graus em relação à temperatura observada, balizando planos de logística agrícola ou urbana com alta precisão.

- **Raiz do Erro Quadrático Médio (RMSE):**

$$\text{RMSE} = \sqrt{\frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2}$$

Interpretação Prática: Por elevar os erros ao quadrado antes de extrair a raiz, o RMSE penaliza severamente desvios de grande magnitude. Se o RMSE se afastar muito do MAE, indica que o modelo está sofrendo falhas graves em dias de viradas bruscas de frentes frias simuladas no gerador.

9. Limitações Estruturais e Cenários de Falha

Em alinhamento com as boas práticas de Ciência de Dados, o sistema reconhece as fronteiras operacionais dos modelos aplicados:

- **Impossibilidade de Captura do Ruído Branco:** O gerador de dados inclui instabilidades diárias puramente aleatórias (distribuição normal). Nenhum modelo preditivo baseado unicamente em histórico temporal consegue antecipar a aleatoriedade estocástica pontual.
- **Limitação de Extrapolação do Random Forest:** Árvores de decisão são incapazes de prever valores acima ou abaixo do teto observado no conjunto de treinamento. Portanto, o `RandomForestRegressor` falha ao tentar projetar o avanço contínuo do aquecimento global nos anos futuros de teste, tendendo a estabilizar as previsões na média histórica.
- **Limitação da Regressão Linear:** Assume rigidez matemática absoluta. Se o padrão climático sofrer uma alteração abrupta não-linear (como quebra na taxa de aquecimento), o modelo linear continuará projetando a tendência antiga indefinidamente.

10. Infraestrutura DevOps e Inicialização Unificada

Atendendo à premissa de reprodutibilidade em comando único, os limites e conexões de rede interna do ecossistema foram isolados via contêineres Docker:

```
# Inicializacao em comando unico a partir da raiz do projeto
$ docker-compose up --build
```

Mapeamento de Serviços e Portas Físicas Mapeadas

- db (**PostgreSQL 15**): Porta interna dedicada, populada automaticamente na primeira execução através do ponto de entrada do gerador.
- api (**FastAPI**): Porta 8000. Isola as conexões de banco e expõe as rotas de dados estruturados.
- app (**Streamlit**): Porta 8501. Interface gráfica focada em UX que interage com o usuário e consome unicamente as respostas JSON da API.

11. Conclusão e Resultados

- **Arquitetura Escalável:** O desacoplamento total viabilizou um ecossistema limpo, performático e pronto para a substituição de qualquer das camadas sem impacto sistêmico.
- **pipeline Ponta a Ponta:** O projeto consolida todas as etapas fundamentais de Engenharia e Ciência de Dados: *Ingestão e Simulação* → *Armazenamento Relacional* → *Construção de API REST* → *Modelagem Preditiva Estrita* → *Visualização e Analytics*.
- **Conformidade Operacional:** Ambiente completamente isolado e testado em ambiente limpo, garantindo execução uniforme independente do sistema operacional anfitrião.

Obrigado! Aberto a Perguntas.